

论文中文稿

基于多通道 MRI 与 ResNet34-U-Net 的脑肿瘤切片分割研究

基于当前项目数据、代码与三随机种子实验记录整理

Brain_Tumor_Segmentation 项目

2026 年 8 月

摘要

脑肿瘤 MRI 病灶的自动分割可为定量影像分析提供基础。本文基于 kaggle_3m 数据集，在固定患者级划分下比较普通 U-Net 与 ResNet34-U-Net，并通过随机种子 42、123 和 2026 的配对消融考察三通道输入、轻量增强、ResNet34 编码器和 ImageNet 预训练。M4-P 的测试集 Positive Macro IoU 和 Positive Dice 分别为 0.7664 ± 0.0086 和 0.8425 ± 0.0101 ，在当前八种配置中均值最高。ResNet34 编码器配置的三个种子差值均为正，患者级描述性 bootstrap 区间未跨 0；三通道输入、轻量增强和预训练仅呈弱正向平均趋势，尚未形成跨种子与患者一致的独立增益。本结果仅适用于当前固定测试集和实验协议。

关键词：脑肿瘤分割；磁共振成像；二值语义分割；U-Net；ResNet34；消融实验

1 引言

1.1 研究背景与意义

精准分割多通道 MRI 脑肿瘤切片具有重要临床价值，但人工勾画成本高且易受图像质量影响。病灶边界模糊、尺度和观察者差异会增加轮廓确定难度，自动分割可提供可重复的初始轮廓，为病灶定位、定量分析和人工复核提供基础[1][2]。

现有方法虽已广泛采用深度学习，但多通道信息的互补价值并未在所有数据条件下得到充分利用，输入、增强、编码器和预训练又常被组合加入，难以判断各组件的独立贡献。不严谨的数据组织与验证流程还可能影响比较可信度。本文据此在统一实验条件下构建组件配对对照，重点考察完整方案的整体优势、各组件贡献及其在不同训练状态和病例中的一致性。

1.2 研究对象与问题定义

本文针对 kaggle_3m 数据中的二维 MRI 切片，在患者隔离的统一划分下执行病灶与背景的二值分割。数据标签虽标记为 LGG，但本文暂不讨论 LGG 多类别分类或肿瘤亚区分割。

1.3 本文工作与贡献

- 建立固定清洁清单与隔离划分，统一模型训练、验证和测试所用样本。
- 围绕三通道输入、轻量增强、ResNet34 编码器和 ImageNet 预训练开展多随机种子配对消融。
- 在当前固定测试集上，M4-P 的两项主要阳性切片重叠指标均值最高；ResNet34 编码器配置的配对差值方向最一致，其余组件尚未形成稳定的独立增益证据。

2 相关研究工作

2.1 脑肿瘤 MRI 分割方法

U-Net 及其变体是脑肿瘤分割的基础路线[4][8]，研究已扩展到更丰富的特征表征与输入融合。近期工作通过残差结构改善深层特征学习[5]，以混合注意力强化局部与全局信息协同[10]，并借助预训练权重改善初始化和优化[6]；多模态 MRI 研究则表明，不同序列的互补对比能提供额外信息[3]。这些方向说明输入、编码器与初始化均可能影响分割质量，为本文选择三通道输入、ResNet34 和预训练作为对照因素提供依据。

相关评价通常结合重叠质量、病灶检出、误报与病例差异，单一指标难以完整反映模型行为[4][8]。比较网络方案时，既要关注总体表现，也需结合错误类型和配对结果解释改进来源。

2.2 实验可信度与本文切入点

多数模型改进以组合形式出现，整体性能提高并不能直接拆解输入、增强、结构和预训练的独立贡献；不同组件还可能产生互补或冗余。跨任务方法学研究表明，在同一受试者可产生多个相关观测或增强样本时，非受试者级划分可能造成数据泄漏并高估模型性能[7]；该研究对象为精神疾病计算机辅助诊断，并非脑肿瘤分割，因此本文仅将其作为受试者级划分原则的佐证。本文据此采用固定患者级清单和组件配对对照，以提高内部比较的可核查性。

3 数据与方法

3.1 数据集与清洁清单

本文使用 Kaggle Brain MRI segmentation (LGG Segmentation Dataset) 公开数据集[11]。该数据来源于 TCIA 的 TCGA 低级别胶质瘤集合，提供 MRI 切片及人工 FLAIR 异常区域掩膜，许可为 CC BY-NC-SA 4.0。本文不修改原始文件，仅按内容一致性与通道可用性规则建立固定清洁清单，数据构成见表 1。

表 1 数据集清洁与患者级划分统计

项目	当前已核实内容
患者数	104
切片数	3,629
训练/验证/测试切片	2,619 / 485 / 525

项目	当前已核实内容
训练/验证/测试患者	85 / 9 / 10
正掩膜切片	训练 935、验证 167、测试 173
空掩膜切片	训练 1,684、验证 318、测试 352
当前 tumor_type	清单中均为 LGG
任务类型	单通道输出的二值病灶分割
清洁规则	排除灰度等价患者，并保留清单、文件哈希和分组信息

表中的正掩膜切片表示掩膜含前景，不等同于患者数或肿瘤类别数。

3.2 数据划分与泄漏控制

数据以患者为单位固定划分，同一 group_id 的切片不跨训练集、验证集和测试集，具体构成见表 1。全部模型和随机种子复用同一清单，从数据组织层面隔离相邻切片与个体特征，避免其进入不同集合并影响模型比较。

3.3 图像与掩膜预处理

图像统一缩放至 256×256 ，并按 mean=0.5、std=0.5 归一化；轻量增强配置对训练图像与掩膜同步实施概率为 0.5 的随机水平翻转和最大 $\pm 5^\circ$ 旋转，掩膜以阈值 128 二值化。单通道配置读取原始 RGB 图像的绿色通道作为 FLAIR，三通道配置直接读取原始 RGB 三通道。训练集启用空掩膜平衡，并将正掩膜采样比例设置为 0.40。

3.4 模型结构

本文比较普通 U-Net 与 ResNet34-U-Net。后者以 ResNet34 替换普通卷积编码器，形成多尺度特征金字塔，再由解码器恢复空间分辨率。两类模型均输出单通道病灶概率图，并可接收单通道 FLAIR 或三通道输入。M4-P 的结构见图 1，组件组合见第 4.1 节。




图 1 M4-P 的 ResNet34-U-Net 模型结构

3.5 损失函数与训练策略

全部配置采用 $0.5 \times \text{BCEWithLogits}$ 与 $0.5 \times \text{Positive Dice}$ 的组合损失，优化器为 AdamW，初始学习率 3×10^{-4} 、权重衰减 1×10^{-4} 。训练最多 150 个 epoch，验证指标停滞时降低学习率，早停耐心值为 30，并使用范数 1.0 的梯度裁剪；CUDA 可用时启用自动混合精度，并要求确定性训练。每个随机种子仅依据验证集 Positive Macro IoU 选择最佳检查点，冻结后评估测试集；预测以 0.5 为二值化阈值。实验基于 PyTorch 框架，在单张 NVIDIA GeForce RTX 5060 Laptop GPU 上使用 CUDA 12.8 与混合精度完成。

3.6 评价指标

本文以医学图像分割常用的 Positive Macro IoU 和 Dice 作为主要指标，并使用 Precision、Recall、Micro 指标及空切片误报率补充评价，定义沿用相关研究[4][8][9]。Positive Macro 指标对真实掩膜含病灶的切片等权汇总，突出阳性切片的重叠质量；空切片误报率用于监测背景误激活风险。三个随机种子的结果以均值与样本标准差汇总，测试集不参与模型选择或参数调整。

4 实验设计、结果与讨论

4.1 模型配置与对照设计

实验设置八种配置，以单通道 FLAIR、普通 U-Net、无增强和随机初始化构成 E0 基线，再依次改变三通道输入、轻量增强、ResNet34 编码器与 ImageNet 预训练，具体组合见表 2。该设计既比较完整方案与基线，也通过只改变目标组件的配置形成严格配对。A、B、C、D 分别表示三通道、增强、ResNet34 和预训练；组件结论综合平均方向、种子一致性与病例差异判断。

表 2 八种模型配置与组件对照

配置	输入	主体结构	增强	预训练
E0	单通道 FLAIR	普通 U-Net	无	无
E1-A	三通道	普通 U-Net	无	无
E2-B	单通道 FLAIR	普通 U-Net	轻量增强	无
M0-AB	三通道	普通 U-Net	轻量增强	无
M4-NP	三通道	ResNet34-U-Net	轻量增强	无
M4-P-A	单通道 FLAIR	ResNet34-U-Net	轻量增强	ImageNet
M4-P-B	三通道	ResNet34-U-Net	无	ImageNet
M4-P	三通道	ResNet34-U-Net	轻量增强	ImageNet

4.2 多随机种子实验

八种配置均使用随机种子 42、123 和 2026，在同一固定清单与训练协议下独立训练。本文汇总全部重复实验的均值和样本标准差，不选择单次最高结果；组件效应按相同种子配对计算。24 组 test_metrics.json 的 manifest_sha256 均为 6aee075d9ea8b4a41cdefc372e381a55ec3a099acfaf16002dbde2cd7d5051e7，每次测试均包含 525 张切片（173 张阳性、352 张空切片），且均使用验证集 Positive Macro IoU 对

应的最佳检查点和 0.5 阈值。训练曲线总体下降，但不同配置和随机种子的最佳 epoch 与验证波动存在差异，因此不将其概括为“所有模型均平稳收敛”。

4.3 整体分割表现

表 3 八种模型测试集分割性能（均值±样本标准差）

模型	Test Positive Macro IoU	Test Positive Dice	Test Micro IoU	Precision	Recall	空切片误报率
E0	0.6535 ± 0.0164	0.7342 ± 0.0147	0.6820 ± 0.0228	0.8892 ± 0.0295	0.7453 ± 0.0152	15.81% ± 6.20%
E1-A	0.6629 ± 0.0287	0.7410 ± 0.0343	0.6914 ± 0.0044	0.8683 ± 0.0338	0.7739 ± 0.0307	14.20% ± 5.87%
E2-B	0.7106 ± 0.0072	0.7962 ± 0.0074	0.7326 ± 0.0491	0.8793 ± 0.0830	0.8167 ± 0.0167	14.49% ± 14.60%
M0-AB	0.6961 ± 0.0568	0.7804 ± 0.0504	0.6466 ± 0.1214	0.7673 ± 0.1109	0.7976 ± 0.0850	22.16% ± 12.64%
M4-NP	0.7597 ± 0.0013	0.8356 ± 0.0053	0.7969 ± 0.0254	0.8869 ± 0.0201	0.8868 ± 0.0149	12.03% ± 1.46%
M4-P-A	0.7622 ± 0.0282	0.8402 ± 0.0280	0.8004 ± 0.0120	0.9263 ± 0.0089	0.8550 ± 0.0189	11.17% ± 6.57%
M4-P-B	0.7567 ± 0.0144	0.8357 ± 0.0110	0.7763 ± 0.0457	0.8708 ± 0.0368	0.8765 ± 0.0221	18.94% ± 8.97%
M4-P	0.7664 ± 0.0086	0.8425 ± 0.0101	0.7926 ± 0.0153	0.8710 ± 0.0058	0.8983 ± 0.0239	18.18% ± 2.22%

如表 3 所示，M4-P 的 Positive Macro IoU 和 Positive Dice 均值在当前八种配置中最高；相对 E0 的 Positive Macro IoU 在三个训练种子下均提高。该结果支持“完整配置组合在本固定测试集上的主要阳性切片重叠指标更高”，但不能把总体差异直接分摊给其中每个组件。ResNet34 配对对照的三个种子差值均为正，且患者级描述性 bootstrap 区间未跨 0；其余组件的种子方向不完全一致，患者级区间均跨 0。

不同指标揭示了重叠质量之外的权衡：积极的前景响应有助于覆盖病灶，却可能伴随背景误激活；偏保守的预测则可能提高轮廓纯度，但增加欠分割风险。因此，M4-P 的优势应结合 Precision、Recall 和空切片误报共同理解。完整方案并非在每个病例和

每项指标上均占优，但其主要指标总体领先且跨随机状态方向一致，支持其作为当前综合方案。

4.4 组件消融与作用分析

表 4 组件消融的严格配对结果

组件	严格配对比较	Positive Macro IoU 差值 (均值 ± SD)	患者级平均差值	患者级 bootstrap 95% CI
完整方案	M4-P – E0	+0.1129 ± 0.0249	+0.1053	[+0.0181, +0.2335]
三通道输入 A	M4-P – M4-P-A	+0.0041 ± 0.0366	+0.0027	[-0.0112, +0.0221]
轻量增强 B	M4-P – M4-P-B	+0.0096 ± 0.0148	+0.0112	[-0.0091, +0.0357]
ResNet34 结构 C	M4-NP – M0-AB	+0.0637 ± 0.0579	+0.0673	[+0.0331, +0.1071]
ImageNet 预训练 D	M4-P – M4-NP	+0.0066 ± 0.0075	+0.0001	[-0.0224, +0.0258]

表 4 显示，在本文预设的 Positive Macro IoU 对照中，ResNet34 编码器配置的三个训练种子差值均为正，10 名测试患者的平均差值也均为正；其患者级描述性 bootstrap 95% 区间为[+0.0331,+0.1071]。这些结果支持其为当前四项组件中方向最一致的正向信号。残差和多尺度表征是相关研究提出的设计动机[5]，但本实验没有单独操纵内部残差连接、深度或特征金字塔，不能证明具体机制。

三通道输入、轻量增强和 ImageNet 预训练的平均差值均为正，但三者都只有 2/3 个训练种子为正，患者级描述性 bootstrap 95% 区间也均跨 0。因此，当前证据仅支持“未形成稳定独立增益的弱正向趋势”。多模态互补、增强正则化以及迁移学习初始化是文献中的一般动机[3][6]，不能作为本文差异的已证实机制；尤其不能用当前代码中不存在的“缺失序列填充”解释结果。

组件效应不能简单相加，因为各比较对应不同配置背景。当前证据支持 ResNet34 编码器配置为方向最一致的正向信号；三通道输入、轻量增强和 ImageNet 预训练尚未形成跨训练种子与患者均一致的独立增益。后续应通过更大患者样本、预注册对照、外部验证以及针对输入构成和预训练策略的独立实验重新检验这些组件。

4.5 可视化、误差分析与指标权衡

图 2 第一行比较同一高质量病例上的 E0 与 M4-P。E0 仅覆盖部分病灶并留下较大漏分区域，而 M4-P 的预测范围与真实轮廓更加一致，误差叠加也显示边界遗漏明显减少。这一案例直观对应表 3 中的总体改善：完整方案能够学习更完整的病灶响应，并在保持轮廓连续性的同时提高覆盖能力。不过，定性案例仅用于解释模型行为，整体结论仍由全部测试样本和配对统计支撑。

图 2 第二行集中展示两类关键失败。细小病灶的前景信号有限，经过多次下采样后容易被完全漏检；真实空切片上的局部异常响应则可能形成面积较大的假阳性，增加人工复核负担。两类错误方向相反，分别对应 Recall 不足与 Precision、空切片误报恶化，说明只观察 Dice 或总体像素准确率会遗漏实际风险。后续可结合小病灶重采样、尺度或边界敏感损失、困难样本挖掘及阈值校准进行联合优化，并谨慎评估连通域后处理是否误删真实小病灶。




图 2 E0 与 M4-P 对比及典型失败案例

此外，训练随机性与患者差异分别反映优化波动和病例不确定性。多随机种子与患者级配对汇总显示，完整方案相对 E0、ResNet34 配置相对 M0-AB 的差值方向最一致；其余组件的差值方向不一致。病灶尺度、图像质量或原始 RGB 通道构成是否影响组件收益，当前实验尚未进行预先定义的亚组检验，需在扩大患者样本后另行验证。

5 结论与展望

5.1 结论

本文在固定患者级清单和统一训练协议下比较二维脑肿瘤切片分割方案。M4-P 的 Positive Macro IoU 与 Positive Dice 均值在当前八种配置中最高；ResNet34 编码器配置呈现方向最一致的正向配对信号。三通道输入、轻量增强与 ImageNet 预训练的平均差值为正，但跨训练种子和患者的方向不一致，尚不足以认定为稳定独立增益。

5.2 局限与展望

本研究受限于单一公开数据源、二维架构与有限病例，尚未评估三维体积误差或接受影像科专家盲法评价。当前三通道配置直接使用公开 TIFF 文件中的 RGB 三通道，仓库未提供逐患者原始序列完整性字段，因此不能把结果解释为对完整、独立 MRI 模态组合的验证。现有结果主要反映当前通道构造和受控实验协议下的方法差异。

未来将面向多中心独立数据开展验证，引入相邻切片或三维上下文，并在具有明确序列元数据的数据上分别评估完整模态与缺失模态情形；同时优化增强、医学影像预训练和分层微调，并结合专家盲评、边界修订成本与严重漏检误报分析，评价预测校准和患者亚组稳定性。

参考文献

- [1] GHADIMI D J, VAHDANI A M, KARIMI H, et al. Deep Learning-Based Techniques in Glioma Brain Tumor Segmentation Using Multi-Parametric MRI: A Review on Clinical Applications and Future Outlooks[J]. Journal of Magnetic Resonance Imaging, 2025, 61(3): 1094-1109. DOI: 10.1002/jmri.29543. PMID: 39074952.
- [2] AHAMED M F, HOSSAIN M M, NAHIDUZZAMAN M, et al. A review on brain tumor segmentation based on deep learning methods with federated learning techniques[J]. Computerized Medical Imaging and Graphics, 2023, 110: 102313. DOI: 10.1016/j.compmedimag.2023.102313. PMID: 38011781.
- [3] ABIDIN Z U, NAQVI R A, HAIDER A, et al. Recent deep learning-based brain tumor segmentation models using multi-modality magnetic resonance imaging: a prospective survey[J]. Frontiers in Bioengineering and Biotechnology, 2024, 12: 1392807. DOI: 10.3389/fbioe.2024.1392807. PMID: 39104626.
- [4] WANG T W, HSU M S, LEE W K, et al. Brain metastasis tumor segmentation and detection using deep learning algorithms: A systematic review and meta-analysis[J]. Radiotherapy

and Oncology, 2024, 190: 110007. DOI: 10.1016/j.radonc.2023.110007. PMID: 37967585.

- [5] LI P, LI Z, WANG Z, et al. mResU-Net: multi-scale residual U-Net-based brain tumor segmentation from multimodal MRI[J]. Medical and Biological Engineering and Computing, 2024, 62(3): 641-651. DOI: 10.1007/s11517-023-02965-1. PMID: 37981627.
- [6] POURMAHBOUBI A, ARSALANI SAEED N, TABRIZCHI H. A brain tumor segmentation enhancement in MRI images using U-Net and transfer learning[J]. BMC Medical Imaging, 2025, 25(1): 307. DOI: 10.1186/s12880-025-01837-4. PMID: 40745592.
- [7] LEE H T, CHEON H R, LEE S H, et al. Risk of data leakage in estimating the diagnostic performance of a deep-learning-based computer-aided system for psychiatric disorders[J]. Scientific Reports, 2023, 13(1): 16633. DOI: 10.1038/s41598-023-43542-8. PMID: 37789047.
- [8] KHAN M K H, GUO W, LIU J, et al. Machine learning and deep learning for brain tumor MRI image segmentation[J]. Experimental Biology and Medicine, 2023, 248(21): 1974-1992. DOI: 10.1177/15353702231214259. PMID: 38102956.
- [9] HOEBEL K V, BRIDGE C P, AHMED S, et al. Expert-centered Evaluation of Deep Learning Algorithms for Brain Tumor Segmentation[J]. Radiology: Artificial Intelligence, 2024, 6(1): e220231. DOI: 10.1148/ryai.220231. PMID: 38197800.
- [10] ZHANG Y, HAN Y, ZHANG J. MAU-Net: Mixed attention U-Net for MRI brain tumor segmentation[J]. Mathematical Biosciences and Engineering, 2023, 20(12): 20510-20527. DOI: 10.3934/mbe.2023907. PMID: 38124563.
- [11] BUDA M. Brain MRI segmentation: LGG Segmentation Dataset[DB/OL]. Kaggle. <https://www.kaggle.com/datasets/mateuszbeda/lgg-mri-segmentation> (accessed 2026-08-12). License: CC BY-NC-SA 4.0.